

Отчет по заданию 3: Предсказание последовательности

Муравьев Артем, 318 группа

Содержание

1	Введение	2
2	Этап 1: Увеличение длины предсказания	2
2.1	DLinear: Линейная декомпозиция	2
2.2	Transformer (Base): Механизм внимания	2
2.3	Обоснование принятых решений	3
2.4	Анализ проведенных экспериментов	3
2.5	Заключение по этапу	3
3	Этап 2: Тестирование на альтернативном датасете (Traffic)	4
3.1	Описание данных и параметров	4
3.2	Специфика работы архитектур с транспортными потоками	4
3.3	Анализ проведенных экспериментов на Traffic	5
3.4	Обоснование принятых решений по этапу 2	5
4	Этап 3: Модификация энкодера с переменным шагом (Transformer_MT_VariableStep)	6
4.1	Результаты экспериментов	7
4.2	Анализ и выводы	8
5	Этап 4: Исследование архитектуры без энкодера (Transformer_EncoderFree)	9
5.1	Результаты экспериментов	9
5.2	Анализ и выводы	10
6	Сравнительный анализ всех конфигураций	10
6.1	Выводы по результатам сравнения	12

1 Введение

Данная работа посвящена проверке гипотезы из статьи «Are Transformers Effective for Time Series Forecasting?» (arXiv:2205.13504). Основная цель - сравнение классических и модифицированных архитектур Трансформеров с простой линейной моделью DLinear на задачах долгосрочного прогнозирования.

2 Этап 1: Увеличение длины предсказания

В рамках первого этапа исследования решалась задача долгосрочного прогнозирования временного ряда. Согласно условиям задачи:

- **Горизонт прогнозирования:** увеличен до уровня $24 \times 20 = 480$ временных шагов.
- **Длина входной последовательности:** установлена на уровне 720 шагов.
- **Цель:** провести сравнительный анализ точности и стабильности архитектур **DLinear** и **Transformer (Base)** на сверхдлинных дистанциях.

В данном эксперименте сопоставляются два принципиально разных подхода к моделированию временных рядов.

2.1 DLinear: Линейная декомпозиция

Модель реализует принцип, предложенный в работе arXiv:2205.13504. Она разделяет входной сигнал X на составляющие **Trend-cyclical** и **Seasonal** с помощью операции скользящего среднего. Формально процесс декомпозиции можно описать так:

$$X_{trend} = \text{AvgPool}(X)$$

$$X_{seasonal} = X - X_{trend}$$

Затем к каждой из компонент применяется свой независимый линейный слой, который напрямую отображает историческую последовательность длины 720 в прогноз длины 480. Итоговый прогноз формируется путем взвешенного суммирования:

$$\hat{Y} = X_{trend}W_{trend} + X_{seasonal}W_{seasonal}$$

Такой подход позволяет модели сохранять жесткую временную структуру ряда без использования сложных механизмов внимания, а матрицы весов W становятся легко интерпретируемыми, отражая влияние конкретных исторических шагов на будущие значения.

2.2 Transformer (Base): Механизм внимания

Классическая архитектура Encoder-Decoder, использующая механизм **Multi-head Attention**. В отличие от DLinear, Трансформер проецирует данные в скрытое пространство и вычисляет динамические веса важности для каждого момента времени в истории.

Основой архитектуры является функция масштабированного скалярного внимания:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

где матрицы запросов (Q), ключей (K) и значений (V) формируются линейными проекциями входного ряда, а $\sqrt{d_k}$ выступает в роли нормирующего множителя.

Так как сам по себе механизм внимания инвариантен к перестановкам токенов, для сохранения информации о порядке следования шагов к векторам признаков прибавляется позиционное кодирование. В данной конфигурации энкодер обрабатывает исторический контекст, извлекая сложные нелинейные зависимости, а декодер генерирует целевой прогноз. Однако высокая плотность связей делает эту архитектуру уязвимой к переобучению на шум.

2.3 Обоснование принятых решений

- **Выбор моделей:** Сравнение DLinear и Transformer позволяет проверить гипотезу о том, что для временных рядов прямые линейные отображения зачастую информативнее и надежнее, чем сложные нелинейные зависимости, вычисляемые тяжеловесным механизмом Attention.
- **Настройка обучения:** Для обеих моделей использовался планировщик CyclicLR (`base_lr=1e-5`, `max_lr=1e-3`). Это необходимо для эффективного преодоления плато и выхода из локальных минимумов, что особенно критично для стабилизации градиентов Трансформера.

2.4 Анализ проведенных экспериментов

Сравнительный анализ графиков обучения (Рис. 1) и тестирования (Рис. 2) выявил существенные различия в поведении моделей:

- **Динамика обучения:** Transformer демонстрирует чрезвычайно низкую ошибку на тренировочных данных ($MSE \approx 0.02$). Однако на валидации (Рис. 2, справа) ошибка значительно выше ($MSE \approx 0.07 - 0.11$) и крайне нестабильна. Это свидетельствует о выраженном **переобучении**.
- **Стабильность DLinear:** Линейная модель показывает более высокую ошибку на тренировке ($MSE \approx 1.1$), но при этом разрыв между обучением и тестом минимален. Это говорит о лучшей обобщающей способности DLinear на длинных горизонтах.
- **Характер прогноза:** На сверхдлинном горизонте Трансформер склонен к накоплению ошибки и «размытию» сезонных паттернов, в то время как DLinear стабильно удерживает структуру ряда.

2.5 Заключение по этапу

Эксперимент подтвердил выводы оригинального исследования: при увеличении горизонта прогнозирования классические Трансформеры проигрывают специализированным линейным моделям в стабильности. Высокая емкость Трансформера приводит к переобучению под шум в данных, тогда как декомпозиция в DLinear эффективно выделяет устойчивые компоненты.




Рис. 1: Сравнение Train Loss: DLinear (слева) и Transformer (справа)




Рис. 2: Сравнение Test Loss: DLinear (слева) и Transformer (справа)

3 Этап 2: Тестирование на альтернативном датасете (Traffic)

Целью данного этапа является проверка универсальности исследуемых архитектур на наборе данных **Traffic**, который характеризуется более высокой зашумленностью и ярко выраженными суточными циклами по сравнению с предыдущими выборками.

3.1 Описание данных и параметров

Для эксперимента использовался временной ряд интенсивности движения с сохранением тех же параметров горизонта прогнозирования:

- **Dataset:** Traffic (интенсивность дорожного движения, собираемая с сенсоров).
- **Горизонт прогноза:** 480 шагов.
- **Входное окно:** 720 шагов.

3.2 Специфика работы архитектур с транспортными потоками

Особенности датасета Traffic требуют от моделей разных архитектурных компромиссов:

- **DLinear:** Жестко заданный размер окна скользящего среднего для выделения X_{trend} и $X_{seasonal}$ хорошо справляется с регулярными суточными циклами трафика (например, утренние и вечерние часы пик). Линейный слой, применяемый к сезонной компоненте, формирует стабильный и ровный прогноз, отсекая высокочастотный шум сенсоров. Однако из-за линейной природы модель ограничена в моделировании сложных нелинейных взаимодействий (например, влияние пробок в один час на последующие часы).
- **Transformer:** Динамическая природа Multi-head Attention позволяет вычислять матрицы внимания, которые способны напрямую связывать текущий момент времени с аналогичными часами в предыдущие дни, игнорируя нерелевантные промежутки. Это дает теоретическое преимущество в точности, но высокая плотность параметров делает модель чувствительной к стохастическим выбросам (аварии, аномалии датчиков), что вызывает скачки градиентов при обучении.

3.3 Анализ проведенных экспериментов на Traffic

Анализ результатов, зафиксированных в логах (`DLinear_traffic_test.json` и `Transformer_base_traffic_test.json`), показал следующие результаты:

1. **Сходимость DLinear:** Линейная модель на данном датасете демонстрирует стабильное и плавное снижение ошибки. Согласно логам, итоговая ошибка на тесте составила $MSE \approx 0.140$. Модель успешно адаптировалась к масштабу данных, не показывая признаков расхождения (Рис. 3). Низкая дисперсия ошибки подтверждает устойчивость линейных весов к зашумленным входным сигналам.
2. **Производительность Transformer:** Базовый Трансформер показал более низкую финальную ошибку на тесте ($MSE \approx 0.103$) после 50 эпох обучения. Однако процесс обучения (Рис. 4) характеризуется высокой изменчивостью. Интересно заметить, что на тренировочной выборке Трансформер достиг $MSE \approx 0.08$, что говорит о меньшем переобучении по сравнению с первым этапом. Это объясняется тем, что регулярность суточных циклов трафика позволяет механизму Attention находить более устойчивые паттерны в матрице значений V .
3. **Сравнение архитектур:** В отличие от первого этапа, на датасете Traffic Трансформер смог более эффективно уловить периодические зависимости, превзойдя DLinear по точности. Тем не менее, графики `test_loss` показывают резкие скачки. Это классическая проблема Трансформеров на зашумленных рядах: выбросы во входных данных сильно искажают распределение softmax в блоке внимания, что делает прогнозы DLinear более предсказуемым и безопасным выбором для продуктовых решений, несмотря на чуть большую абсолютную ошибку.

3.4 Обоснование принятых решений по этапу 2

Использование датасета Traffic позволило подтвердить следующие архитектурные свойства:

- Линейная декомпозиция в **DLinear** является надежным базовым решением. Разделение на тренд и сезонность выступает естественным фильтром шума, что позволяет модели работать «из коробки» без сложной настройки гиперпараметров и регуляризации.




Рис. 3: DLinear на датасете Traffic: Train Loss (слева) и Test Loss (справа)




Рис. 4: Transformer на датасете Traffic: Train Loss (слева) и Test Loss (справа)

- **Transformer** на данном датасете выигрывает в точности за счет способности механизма Self-Attention моделировать сложные нелинейные зависимости в трафике. Однако из-за высокой размерности скрытого пространства и отсутствия индуктивного смещения к временной локальности, модель требует тщательного контроля процесса обучения для борьбы с нестабильностью градиентов.

4 Этап 3: Модификация энкодера с переменным шагом (Transformer_MT_VariableStep)

На данном этапе была реализована модификация архитектуры `Transformer_MT_S1`. Основное нововведение заключается в использовании переменного шага и изменяемой длины среза при формировании токенов в энкодере. Цель эксперимента - оценить влияние длины объединения токенов и степени их перекрытия на качество прогнозирования временного ряда на датасете Traffic.

В ходе исследования были протестированы три конфигурации гиперпараметров:

1. **Конфигурация 1:** `input_slice = 12`, `stride = 4`.
2. **Конфигурация 2:** `input_slice = 24`, `stride = 24`.
3. **Конфигурация 3:** `input_slice = 48`, `stride = 12`.

4.1 Результаты экспериментов

Обучение проводилось в течение 50 эпох. Динамика функции потерь MSE для тестовой выборки представлена на графиках ниже.




Рис. 5: Динамика Test Loss: slice=12, stride=4




Рис. 6: Динамика Test Loss: slice=24, stride=24




Рис. 7: Динамика Test Loss: slice=48, stride=12

Итоговые значения наилучшей функции потерь зафиксированы в логах обучения и сведены в таблицу 1.

Модель	Конфигурация (Slice / Stride)	Train Best Loss (MSE)	Test Best Loss (MSE)
Transformer_MT_VariableStep	12 / 4	0.0520	0.0464
Transformer_MT_VariableStep	24 / 24	0.0478	0.0418
Transformer_MT_VariableStep	48 / 12	0.0436	0.0384

Таблица 1: Сравнение качества моделей с различным шагом токенизации

4.2 Анализ и выводы

На основе полученных данных можно сделать следующие выводы:

- **Преимущество широкого контекста:** Наилучший результат ($MSE \approx 0.0384$) продемонстрировала модель с наибольшим размером патча (slice = 48). Значит, для данного временного ряда способность токена инкапсулировать более длительный исторический контекст важнее, чем высокая гранулярность признаков.
- **Влияние перекрытия:** Сравнение конфигураций показывает, что наличие перекрытия работает эффективно только в сочетании с достаточно большим размером токена. В конфигурации 48/12 перекрытие помогает сохранить непрерывность между длинными патчами. Но при коротких токенах (12/4) сильное перекрытие приводит к избыточности и худшему результату на тесте ($MSE \approx 0.0464$).
- **Стабильность обучения:** Визуальный анализ подтверждает, что при slice = 48 и stride = 12 кривая функции потерь на тестовой выборке сходится наиболее плавно, избегая сильных осцилляций на поздних эпохах, характерных для Трансформеров. Жесткая нарезка (slice = 24, stride = 24) показывает промежуточный результат ($MSE \approx 0.0418$), выступая надежной, но не лучшей базой.

Таким образом, переход к переменному шагу агрегации оказался полезен. Он доказал, что баланс между размером поля энкодера и шагом скольжения позволяет существенно снизить ошибку прогнозирования.

5 Этап 4: Исследование архитектуры без энкодера (Transformer_EncoderFree)

На четвертом этапе была рассмотрена модификация архитектуры - `Transformer_EncoderFree`. В данной модели из структуры Трансформера был полностью исключен модуль энкодера. Цель этого эксперимента - проверить гипотезу о том, насколько значимо предварительное извлечение признаков и расчет Self-Attention на исторических данных для задачи прогнозирования временного ряда (датасет Traffic).

5.1 Результаты экспериментов

Обучение проводилось в течение 50 эпох со стандартными гиперпараметрами. Динамика функции потерь MSE для обучающей и тестовой выборок представлена на графиках ниже.




Рис. 8: Динамика Train Loss для модели `Transformer_EncoderFree`




Рис. 9: Динамика Test Loss для модели Transformer_EncoderFree

Итоговые значения наилучшей функции потерь зафиксированы в логах и сведены в таблицу 2.

Модель	Train Best Loss (MSE)	Test Best Loss (MSE)
Transformer_EncoderFree	0.0933	0.1158

Таблица 2: Метрики качества модели без энкодера

5.2 Анализ и выводы

Анализ полученных данных позволяет сделать следующие выводы:

- **Деградация качества прогноза:** По сравнению с лучшей моделью предыдущего этапа (Transformer_MT_VariableStep с $MSE \approx 0.0384$), качество прогнозирования упало почти в три раза. Тестовая ошибка зафиксировалась на уровне $MSE \approx 0.1158$.
- **Проблема извлечения контекста:** Отсутствие энкодера лишает модель возможности строить глубокие контекстно-зависимые представления исторического окна. Декодеру или линейному слою приходится работать с недостаточно обогащенными патчами, что критично для датасета Traffic, обладающего сложной сезонностью.
- **Характер сходимости:** На графике тестовой выборки видно, что лосс быстро выходит на плато и практически не улучшается, колеблясь в узком диапазоне. Это классический признак недообучения из-за недостаточной емкости модели или отсутствия необходимых архитектурных блоков для улавливания сложных паттернов.

6 Сравнительный анализ всех конфигураций

Для оценки эффективности предложенных модификаций был проведен сравнительный анализ всех протестированных конфигураций архитектуры Transformer. На рисунках

ниже представлены сводные графики функции потерь MSE на обучающей и тестовой выборках в зависимости от количества эпох обучения.




Рис. 10: Сравнение динамики Train Loss для всех исследованных конфигураций




Рис. 11: Сравнение динамики Test Loss для всех исследованных конфигураций

Итоговое сопоставление целевых метрик MSE представлено в сводной таблице 3.

Архитектура	Конфигурация	Train MSE	Test MSE
VariableStep (Лучшая)	48 / 12	0.0436	0.0384
VariableStep	24 / 24	0.0478	0.0418
VariableStep	12 / 4	0.0520	0.0464
EncoderFree	—	0.0933	0.1158

Таблица 3: Сводные результаты этапов 3 и 4

6.1 Выводы по результатам сравнения

На основе анализа сводных графиков итерационного обучения можно сделать следующие обобщающие выводы:

- **Критическая роль энкодера:** На сводных графиках отчетливо виден значительный отрыв кривой **EncoderFree** от остальных моделей. Это подтверждает, что механизм Self-Attention в энкодере является ключевым для формирования репрезентативных векторов состояния временного ряда. Без него модель теряет способность к долгосрочному планированию.
- **Зависимость от гранулярности токенов:** Сравнение трех кривых **VariableStep** показывает стабильную иерархию: увеличение размера среза при умеренном шаге планомерно снижает ошибку. Это указывает на то, что для транспортных потоков глобальные паттерны несут больше полезной информации, чем локальные флуктуации.
- **Стабильность обучения:** Все конфигурации с энкодером демонстрируют монотонное убывание ошибки на валидационной выборке без признаков выраженного переобучения к 50-й эпохе. Модель без энкодера не только показывает худший результат, но и имеет более высокую дисперсию ошибки на последних итерациях, что говорит о нестабильности извлеченных признаков.

Таким образом, наиболее эффективной конфигурацией признана модель **Transformer_MT_VariableStep** с параметрами `slice=48`, `stride=12`, сочетающая в себе глубокий контекст и механизм перекрытия токенов.